



UNIVERSITA' DEGLI STUDI DI TORINO

Dipartimento di Informatica

Corso di Laurea Magistrale in Informatica

Anno Accademico 2024/2025

Tecnologie del Linguaggio Naturale-Parte III Prof. L. Di Caro

Autore: Annalisa Sabatelli Matr. 866879

LAB-3

Valutazione delle definizioni: *Content-to-Form*

1. Introduzione

La seguente esercitazione ha affrontato il problema della ricerca onomasiologica che consiste nell'individuare un concetto a partire dalla sua definizione. Nello specifico, si prova a risalire al synset partendo dalle definizioni dei concetti contenute nel file *dataset_definizioni_TLN_25.xlsx* già utilizzato nel laboratorio 2.

L'approccio adottato per l'analisi semantica dei concetti si articola in più fasi complementari. In primo luogo, per ogni definizione associata ad un concetto vengono estratti i due elementi fondamentali della definizione stessa: il genus, che rappresenta la categoria generale del concetto, e la differentia, ossia gli attributi distintivi che lo caratterizzano rispetto al genus. Successivamente, a partire dal genus identificato, si esplora la rete di WordNet per individuare tutti i possibili synset tra gli iponimi del genus che possano rappresentare semanticamente la definizione. Per ciascun synset candidato viene calcolato un punteggio di cosine similarity confrontando l'embedding della

definizione del synset eventualmente concatenata con gli esempi con l'intera definizione originale. In questo modo è possibile selezionare i synset che meglio rispecchiano il contenuto informativo della definizione.

Parallelamente, per ciascun concetto viene identificata la lista dei synset di riferimento (target) direttamente tramite il lemma del concetto stesso. Questa lista non guida la ricerca, ma funge da punto di riferimento per valutare quanto i synset trovati partendo dalla definizione siano vicini o lontani dalla rappresentazione canonica del concetto all'interno di WordNet.

Infine, i risultati vengono organizzati in forma tabellare, mostrando per ogni definizione il genus, la differentia, i synset con il punteggio più alto e il confronto rispetto ai synset target del concetto. Questa rappresentazione consente di evidenziare chiaramente la qualità delle corrispondenze individuate e di identificare eventuali discrepanze tra la definizione testuale e la classificazione semantica in WordNet.

2. Struttura del codice

Il codice è diviso in 2 file:

- *utils.py*: contiene metodi di utility di cui se ne riportano i principali
 - *def extraction_lemmi_from_sentence(sentence)*: metodo che prende in input una frase e la elabora restituendo un set costituito dai lemmi delle parole che la costituiscono. In particolare, l'elaborazione si articola nei seguenti passi:
 - tokenizzazione;
 - rappresentazione di tutte le parole in lower case;
 - rimozione delle stop-words;
 - rimozione della punteggiatura e/o numeri;
 - creazione di una stringa di lemmi separati da spazi.
 - *def create_dictionary()*: metodo che prende in input un file .xlsx di definizioni per ciascun concetto, lo trasforma in .csv e lo traduce in inglese. Successivamente a partire dal file così ottenuto crea una struttura dati di tipo dizionario che associa a ciascun concetto le sue definizioni.
 - *def extract_genus_and_differentia_dependency(definizione)*: Questa funzione prende in input una definizione scritta in linguaggio naturale e cerca di scomporla nei suoi due elementi fondamentali: il genus, cioè la categoria generale a cui appartiene il concetto, e la differentia, cioè tutto ciò che lo caratterizza e lo distingue dagli altri membri della stessa categoria. Per fare questo, viene utilizzata la libreria spaCy, che legge la definizione e la analizza dal punto di vista grammaticale e sintattico. Partendo da questa analisi, la

funzione cerca di capire qual è il termine che meglio rappresenta il genus secondo la seguente logica:

- se la parola principale della frase (la “ROOT”) è un nome lo si assume come genus;
- altrimenti viene cercato un soggetto della frase che sia un nome;
- altrimenti viene preso semplicemente il primo nome disponibile nella definizione.

Trovato il genus, la differentia è, in prima istanza, il resto delle parole della definizione privata del genus.

- *def process_definizioni (definizioni_dict):* il metodo elabora un insieme di definizioni associate ai vari concetti, arricchendole con ulteriori informazioni linguistiche e semantiche. Per ogni concetto individua innanzitutto i synset di WordNet che potrebbero rappresentarlo (synset target), creando così un insieme di candidati di riferimento. Successivamente, per ciascuna definizione estrae il genus e la differentia tramite analisi sintattica, e, se il genus è presente, tenta di disambiguarlo navigando nella rete semantica di WordNet tra i suoi iponimi selezionando il synset che ottiene il punteggio di similarità più alto rispetto alla definizione. Infine, aggiorna le definizioni con genus, differentia, synset migliore, glossa del miglior synset selezionato, punteggio di similarità rispetto al synset target e lista dei synset target.
- *def explore_synset_tree(synset, definizione, depth=0, max_depth=2, visited=None):* il metodo esplora ricorsivamente la gerarchia di WordNet partendo da un synset iniziale. Ad ogni passo valuta quale synset si avvicina di più alla definizione in input usando un modello Word2Vec per calcolare la similarità semantica. Alla fine restituisce: il miglior synset trovato e il suo punteggio di similarità.
- *def score_against_definition_word2vec(synset, definizione, w2v_model):* il metodo calcola la similarità semantica tra una definizione e la glossa di un synset di WordNet utilizzando Word2Vec. Il processo avviene in tre fasi: prima la definizione e la glossa vengono lemmatizzate per ridurre le parole alle loro forme base. Successivamente, per entrambe le frasi, si costruisce un vettore medio calcolando la media dei vettori Word2Vec delle parole presenti, scartando quelle non contenute nel modello. Infine, la similarità tra i due vettori medi viene calcolata tramite cosine similarity, producendo uno score numerico che misura quanto i due testi siano semanticamente vicini. Rispetto al TF-IDF, che si basa unicamente su frequenze di parole e quindi cattura solo somiglianze lessicali superficiali, Word2Vec ha il vantaggio di rappresentare le parole in

uno spazio vettoriale continuo che preserva le relazioni semantiche rendendo l'analisi più robusta e significativa.

- *main.py*: indica il flusso di esecuzione delle operazioni

3. Risultati ottenuti

Si riportano i risultati ottenuti a valle dell'esecuzione del codice. Per ogni concetto si riportano i primi 5 risultati più significativi ordinati secondo cosine similarity decrescente.

Risultati - Top 5 per concetto							
Categoria	Definizione_originale	Genus	Differentia	Synset_best_score	Glossa_synset_best_score	Best_score	Synset ammissibili per concetto
Trousers	garment	garment	–	undergarment.n.01	a garment worn under other garments	0.9365419	['trouser.n.01', 'trouser.n.02']
Trousers	Garment to be worn from the life down	garment	to be wear from the life down	undergarment.n.01	a garment worn under other garments	0.90563333	['trouser.n.01', 'trouser.n.02']
Trousers	garment worn on the legs	garment	wear on the leg	undergarment.n.01	a garment worn under other garments	0.88308066	['trouser.n.01', 'trouser.n.02']
Trousers	Garment used to be worn at the bottom of the body	garment	use to be wear at the bottom of the body	shirt.n.01	a garment worn on the upper half of the body	0.86815685	['trouser.n.01', 'trouser.n.02']
Trousers	garment that can be worn in the lower part of the body	garment	that can be wear in the low part of the body	shirt.n.01	a garment worn on the upper half of the body	0.86515003	['trouser.n.01', 'trouser.n.02']
Microscope	Optical or electronic device to inspect very small objects and usually not visible to the naked eye	device	optical or electronic to inspect very small object and usually not visible to the naked eye	autofocus.n.01	an optical device for focussing a camera or other instrument automatically	0.7048125	['microscope.n.01']
Microscope	A scientific device that uses lenses to enlarge objects	device	a scientific that use lense to enlarge object	camera_lucida.n.01	an optical device consisting of an attachment that enables an observer to view simultaneously the image and a drawing surface for sketching it	0.6808982	['microscope.n.01']
Microscope	device used for the analysis and vision of small details invisible to the naked eye in objects of various kinds	device	use for the analysis and vision of small detail invisible to the naked eye in object of various kind	camera_lucida.n.01	an optical device consisting of an attachment that enables an observer to view simultaneously the image and a drawing surface for sketching it	0.65601414	['microscope.n.01']

Microscope	Tool that allows you to enlarge objects and elements up to a scale impossible to reach with the naked eye.	tool	that allow you to enlarge object and element up to a scale impossible to reach with the naked eye	bevel.n.02	a hand tool consisting of two rules that are hinged together so you can draw or measure angles of any size	0.6493176	['microscope.n.01']
Microscope	device to see objects visible only in the cell stairs	device	to see object visible only in the cell stair	kerr_cell.n.01	optical device consisting of a transparent cell with two electrodes between two polarizing media; passes light only if the two planes of polarization are parallel; used as a high-speed shutter or to modulate a laser beam	0.64653957	['microscope.n.01']
Danger	risk, threat	risk	threat	chance.n.03	a risk involving danger	0.7626179	['danger.n.01', 'risk.n.02', 'danger.n.03', 'danger.n.04']
Danger	Potentially risky situation	situation	potentially risky	situation.n.03	a complex or critical or unusual difficulty	0.75234056	['danger.n.01', 'risk.n.02', 'danger.n.03', 'danger.n.04']
Danger	perception of a threat situation	perception	of a threat situation	penetration.n.02	clear or deep perception of a situation	0.7416901	['danger.n.01', 'risk.n.02', 'danger.n.03', 'danger.n.04']
Danger	It is a frightening and anxious situation that can lead to very bad events.	situation	it be a frightening and anxious that can lead to very bad event	pass.n.08	a bad or difficult situation or state of affairs	0.7407152	['danger.n.01', 'risk.n.02', 'danger.n.03', 'danger.n.04']
Danger	threat	threat	—	menace.n.02	a threat or the act of threatening	0.7267646	['danger.n.01', 'risk.n.02', 'danger.n.03', 'danger.n.04']

Heuristic	Assumption of facts in the hypothesis of work that guide the process	assumption	of fact in the hypothesis of work that guide the process	assumption.n.02	a hypothesis that is taken for granted	0.7361653	['heuristic.n.01', 'heuristic.a.01']
Heuristic	Problem solving approach	problem	solve approach	problem.n.02	a question raised for consideration or solution	0.73479986	['heuristic.n.01', 'heuristic.a.01']
Heuristic	rule that allows you to approximate an excellent solution to a problem	rule	that allow you to approximate an excellent solution to a problem	heuristic.n.01	a commonsense rule (or set of rules) intended to increase the probability of solving some problem	0.7181356	['heuristic.n.01', 'heuristic.a.01']
Heuristic	estimates that it is used to calculate the most optimal costs in the search for algorithmic solutions in the IT field	cost	estimate that it be use to calculate the most optimal in the search for algorithmic solution in the IT field	unit_cost.n.01	calculated cost for a given unit of a product	0.7066176	['heuristic.n.01', 'heuristic.a.01']

4. Conclusioni

I risultati ottenuti mettono in luce le difficoltà insite nel processo di disambiguazione automatica. Con Word2Vec si è visto che il modello riesce in alcuni casi, come per Heuristic, a individuare il synset corretto ma fallisce frequentemente con termini come Trousers, Microscope o Danger, producendo punteggi alti anche per synset non pertinenti, evidenziando difficoltà a distinguere tra concetti semanticamente vicini ma concettualmente distinti. Questo suggerisce che, sebbene le rappresentazioni distribuzionali colgano efficacemente le associazioni lessicali, esse non garantiscono una sufficiente precisione nel legare una definizione a un significato univoco. Un aspetto interessante è che i risultati sono stati simili anche considerando modelli transformer

decisamente più capaci: non si è registrato un netto miglioramento in termini di accuratezza. Questo porta a concludere che la disambiguazione lessicale rimane un compito complesso, che non può basarsi esclusivamente sulla similarità semantica appresa dai modelli ma necessita probabilmente di strategie ibride capaci di integrare rappresentazioni distribuzionali, conoscenza contestuale e vincoli semantici espliciti.