



# UNIVERSITA' DEGLI STUDI DI TORINO

Dipartimento di Informatica

Corso di Laurea Magistrale in Informatica

Anno Accademico 2024/2025

## **Tecnologie del Linguaggio Naturale-Parte III Prof. L. Di Caro**

Autore: Annalisa Sabatelli Matr. 866879

### PROGETTO

## Realizzazione di un motore di Question Answering basato su RAG per il manuale FISE di Equitazione

### **1. Introduzione**

La Federazione Italiana Sport Equestri (FISE) mette a disposizione un ampio corpus normativo e tecnico attraverso i propri manuali ufficiali, fondamentali per la formazione e l'aggiornamento di atleti, istruttori e giudici. Tuttavia, la consultazione di questi è ancora saldamente ancorata ad un approccio tradizionale basato sulla consultazione di pdf i cui indici degli argomenti sono troppo spesso generici e poco articolati. La consultazione di tali documenti risulta perciò tipicamente complessa e poco immediata soprattutto per gli atleti più giovani e meno esperti, specialmente quando si ha la necessità di reperire rapidamente informazioni specifiche per la preparazione per gli esami di federazione. In questo contesto, la realizzazione di un sistema **RAG (Retrieval**

**Augmented Generation**) applicato al manuale di equitazione FISE rappresenta una soluzione innovativa: combina la potenza dei modelli linguistici generativi con la capacità di ricerca semantica, consentendo all'utente di porre domande in linguaggio naturale e ricevere risposte precise, contestualizzate e basate direttamente sul contenuto ufficiale. Questo progetto mira quindi a migliorare l'accessibilità, la fruibilità e l'efficacia nell'utilizzo del Manuale di Equitazione di base, favorendo un apprendimento più rapido e un supporto decisionale affidabile.

## 2. Struttura e Funzionamento del Sistema RAG

### 2.1.Paradigma RAG

Il progetto si fonda sull'adozione del paradigma RAG (Retrieval-Augmented Generation), una metodologia ibrida che combina il recupero di informazioni con la generazione linguistica per ottenere risposte più accurate e contestualizzate. Un sistema RAG si struttura attorno a due componenti principali:

- *Retriever* (Componente di Recupero): ha il compito di individuare i segmenti di testo più pertinenti all'interno di una base documentale preesistente che in questo caso è costituita dal manuale ufficiale FISE di equitazione. La componente di retrieval può utilizzare motori di ricerca tradizionali basati su parole chiave o indici oppure può essere basata su embedding. In quest'ultimo caso ogni paragrafo o "chunk" del manuale viene trasformato in un vettore numerico che ne rappresenta il contenuto semantico, permettendo di confrontare la similarità tra query e documenti. L'obiettivo del retriever è, quindi, ridurre lo spazio di ricerca, selezionando solo le informazioni più rilevanti da fornire al generatore, garantendo efficienza e precisione.
- *Generator* (Componente di Generazione): Il generator è un modello linguistico di grandi dimensioni (LLM) che utilizza come contesto i documenti recuperati dal retriever per produrre una risposta in linguaggio naturale. Grazie a questa componente le risposte sono coerenti, fluide e leggibili, simili a quelle di un esperto umano.

Il lavoro congiunto di queste due componenti, se adeguatamente progettate, garantisce che la risposta ad una query dell'utente debba includere solo e soltanto i contenuti ufficiali del manuale, consentendo di superare alcune limitazioni tipiche degli LLM, come l'obsolescenza delle informazioni e il rischio di generare contenuti non supportati dalle fonti (allucinazioni).

### 2.2.Architettura del sistema RAG

L'architettura del sistema è progettata per implementare il paradigma RAG in maniera modulare, garantendo scalabilità, manutenibilità e facilità di aggiornamento. Il flusso si articola in diverse fasi successive, ciascuna con un ruolo specifico:

## *1. Ingestion e parsing dei documenti*

Generalmente, il corpus di documenti di partenza necessita di un'accurata fase di pre-processing, finalizzata a ottenere un testo ben strutturato e organizzato in capitoli, sezioni e sottoparagrafi. Tale fase comporta, ad esempio, la rimozione di elementi non testuali (figure, didascalie, piè di pagina e formattazioni grafiche), in modo da produrre documenti lineari, corretti dal punto di vista sintattico e grammaticale e con una formattazione essenziale. Un testo semplificato e chiaro facilita infatti il lavoro della componente di retrieval: quanto più il contenuto di input è pulito, tanto più agevole e accurata sarà l'individuazione dei frammenti significativi utili a rispondere a una query, soprattutto nel caso in cui si utilizzino modelli di retrieval non particolarmente potenti.

Il pre-processing richiede in genere la definizione di un metodo automatico capace di estrarre il testo dai documenti, combinando tecniche come le espressioni regolari (regex) e, in alcuni casi, il supporto di LLM (ad esempio i modelli OpenAI), per gestire le strutture di testo più complesse.

Nel caso specifico di questo lavoro, il manuale FISE è disponibile in formato pdf ma la sua struttura risulta eterogenea e difficilmente trattabile con semplici regex. Sono stati effettuati diversi tentativi di estrazione automatica che hanno prodotto risultati in parte soddisfacenti ma caratterizzati da imprecisioni sintattiche e grammaticali. Tali imperfezioni hanno inciso negativamente sulle prestazioni complessive del sistema RAG nella fase di ricerca e, come conseguenza, anche in quella di generazione, con un impatto negativo amplificato dalla successiva traduzione in lingua inglese e dall'utilizzo di modelli linguistici non particolarmente avanzati.

Per questi motivi, si è scelto di effettuare la preparazione del testo manualmente, così da garantire la qualità e l'affidabilità del corpus di riferimento.

Un passaggio cruciale della fase di ingestion è rappresentato dal chunking dei documenti, ovvero la suddivisione del testo in blocchi (chunk) di dimensioni gestibili, che possano essere indicizzati e successivamente recuperati in fase di interrogazione. Esistono due principali approcci:

- **Chunking dimensionale:** la suddivisione avviene in base alla lunghezza del testo, ad esempio per numero di caratteri, token o frasi, senza tenere conto della struttura semantica.
- **Chunking semantico:** il testo viene segmentato includendo all'interno dello stesso chunk contenuti contigui e semanticamente coerenti, in modo da preservare il significato e il contesto.

Nel presente lavoro sono stati sperimentati entrambi gli approcci, valutandone l'impatto sulle prestazioni del sistema RAG. I risultati hanno mostrato che il chunking dimensionale ha prodotto performance migliori rispetto a quello semantico. Una spiegazione plausibile risiede nel fatto che i modelli LLM impiegati non erano particolarmente potenti: in questi casi, chunk più semplici e regolari dal punto di vista dimensionale risultano più facili da gestire ed elaborare, mentre chunk più ampi e semanticamente ricchi richiedono modelli con maggiore capacità di comprensione e contestualizzazione. In particolare, è stato verificato che la lunghezza ottimale del chunk, ossia quella che ottimizza retrieval e generazione è di 400 token con 50 token di overlap.

## *2. Creazione degli embedding e indicizzazione*

Ogni chunk viene trasformato in un vettore semantico attraverso un modello di embedding, così da rappresentarne il contenuto in uno spazio numerico adatto alle operazioni di similarità. Questi vettori vengono poi memorizzati in un vector store, ossia una base dati specializzata che consente ricerche per similarità semantica e costituisce la base di conoscenza interrogabile dal sistema RAG.

Nel caso specifico di questo progetto, è stato scelto di utilizzare ChromaDB come motore di archiviazione, configurato nella modalità persistente per garantire che i dati rimangano disponibili anche dopo la chiusura del processo. Tutti i metodi per la creazione dei vari componenti del RAG sono contenuti nel file *rag\_utils.py*. La funzione *setup\_vector\_store()* si occupa di creare (o recuperare, se già esistente) una collezione chiamata *rag\_collection*, che funge da contenitore dei vettori.

Successivamente, la funzione *build\_index()* ha il compito di indicizzare i chunk preprocessati: attraverso un *StorageContext* che punta al vector store, i documenti vengono caricati e organizzati in un *VectorStoreIndex*. Infine, l'indice e il relativo store vengono salvati in locale nella cartella *./chroma\_db*, rendendo così possibile il loro riutilizzo senza dover ripetere ogni volta l'intera procedura di ingestion e indicizzazione.

## *3. Componente di retrieval*

Alla ricezione di una query da parte dell'utente, questa viene trasformata in un embedding e confrontata con i vettori presenti nel vector store. In questo modo, il sistema è in grado di individuare i chunk più rilevanti rispetto alla richiesta, restituendo un sottoinsieme limitato di documenti pertinenti che costituirà il contesto da passare alla fase di generazione.

Dal punto di vista implementativo, questa logica è stata isolata nella funzione *build\_retriever()*. A partire dall'indice costruito in fase di indicizzazione, viene istanziato un retriever tramite il metodo *index.as\_retriever(top\_k=top\_k)*. Il parametro *top\_k* consente di controllare il numero massimo di chunk da restituire per ogni query: in questo caso, è stato impostato di default a 5, così da garantire un buon equilibrio tra completezza informativa (includere più fonti potenzialmente utili) e riduzione del rumore (evitare di fornire al modello un contesto troppo ampio e dispersivo). La scelta di separare il retriever in una funzione dedicata risponde a esigenze di modularità: in questo modo la componente può essere facilmente sostituita o ottimizzata (ad esempio variando *top\_k*, sperimentando diversi modelli di embedding o introducendo filtri semantici) senza modificare il resto della pipeline RAG.

#### 4. Componente di generazione

I chunk recuperati nella fase di retrieval vengono passati come contesto al modello linguistico (LLM), che elabora una risposta in linguaggio naturale. In questo modo la generazione è guidata direttamente dal contenuto ufficiale del manuale FISE, garantendo coerenza con le fonti e riducendo la probabilità di errori o allucinazioni tipiche dei modelli puramente generativi.

Dal punto di vista implementativo, questa logica è stata incapsulata nella funzione *build\_generator()* che costruisce un synthesizer tramite il metodo *get\_response\_synthesizer()*, che definisce la strategia di produzione della risposta. In particolare, è stato adottato il *response\_mode="refine"*, una modalità che permette di generare una prima bozza di risposta a partire dai chunk iniziali e di raffinarla progressivamente man mano che vengono integrati gli altri documenti recuperati.

Infine, retrieval e generazione vengono integrati all'interno della funzione *build\_query\_engine()*. Questa unificazione avviene tramite il metodo *RetrieverQueryEngine.from\_args()*, che combina il retriever e il generatore in un unico motore di ricerca e risposta.

Una componente fondamentale per il corretto funzionamento del query engine è il prompt template utilizzato per guidare il modello linguistico. L'adozione di un prompt accuratamente progettato, ben contestualizzato e dotato di istruzioni precise sull'output atteso può influenzare in modo significativo le prestazioni del sistema, determinandone la qualità, la coerenza e l'affidabilità delle risposte generate. Nel progetto, il prompt è stato costruito per fornire al modello un contesto chiaro e vincolante, orientando la generazione verso informazioni estratte esclusivamente dal manuale di equitazione FISE. Di seguito si riporta il template adottato:

```
custom_prompt_str = """
You are an experienced riding instructor, skilled in training, equine
ethology, and horse anatomy.
The context provided will be about horse and it is taken from Horsemanship
manual.
Answer the question **strictly using the context below** and include any
**relevant facts** you find only in the context. Be concise but
informative.
Don't add comments or information not included in the context.
**IMPORTANT** if the context doesn't contain useful information for the
answer, say that you are not able to answer."
```

Questo prompt impone al modello di rispondere solo sulla base del contesto fornito, evitando informazioni inventate o non verificate, di essere conciso ma informativo, includendo tutti i dati rilevanti presenti nei chunk, di riconoscere quando il contesto non è sufficiente e indicare chiaramente la propria impossibilità a rispondere.

In tal modo, il prompt garantisce che il sistema fornisca risposte coerenti, affidabili e tracciabili, minimizzando il rischio di allucinazioni e migliorando l'accuratezza complessiva del query engine.

## 5. *Output e tracciabilità*

Oltre a fornire una risposta sintetica, il sistema riporta i riferimenti ai chunk originari del manuale, consentendo all'utente di verificare la provenienza delle informazioni e mantenendo la massima trasparenza.

Per la realizzazione del sistema RAG è stata adottata la libreria llamaIndex, scelta per la sua capacità di integrare in maniera modulare un modello linguistico con un motore di retrieval basato su vector store consentendo di gestire in modo semplice la pipeline completa, dall'ingestione dei documenti alla generazione di risposte.

## 2.3. Interfaccia utente con Streamlit

Per rendere l'interazione con il sistema RAG semplice e accessibile anche a utenti non tecnici, è stata sviluppata un'interfaccia web utilizzando Streamlit, una libreria Python orientata alla prototipazione rapida di applicazioni data-driven.


L'interfaccia è composta da tre sezioni principali:

- Campo di input della query: l'utente può inserire domande in linguaggio naturale in lingua inglese, senza necessità di conoscere la struttura interna del sistema.
- Sezione di risposta: mostra l'output generato dall'LLM, che sintetizza le informazioni provenienti dal manuale.
- Sezione dei chunk recuperati: consente di visualizzare i passaggi originali del documento con relativo punteggio di similarità, garantendo tracciabilità e trasparenza nella costruzione della risposta.

Sono stati inoltre aggiunti elementi di usabilità, come un indicatore di caricamento durante le operazioni di retrieval e generazione, la possibilità di visualizzare i chunk in pannelli espandibili e un pulsante di terminazione dell'applicazione.

La figura seguente mostra la semplice interfaccia utente ed un esempio di query “*Describe main features of grey coat horse*” alla quale il sistema ha risposto in modo coerente rispetto alle informazioni messe a disposizione dal manuale.

Per avviare il RAG da terminale, è necessario posizionarsi nella cartella del progetto e lanciare il comando: `streamlit run app.py`.



Enter your question and consult the FISE Horsemanship manual.

Write your question here:

Describe main features of grey coat horse

Number of chunks retrieved: 1

### Generated Answer

**\*\* Grey coat horses have a characteristic color pattern where black and white hairs are evenly distributed on black skin, creating a grey appearance. The body is brown in varying shades, with the extremities and mane also being black.\*\***

### Retrieved Chunks

> Chunk 1 (Score: 3.6045898619156536e-14)

## 3. Risultati ottenuti

Nei test effettuati sul sistema RAG sviluppato, è stato possibile inserire soltanto 9 capitoli su 15, per un massimo di circa 13.000 parole. Oltre questa soglia, è stato osservato che il modello iniziava a generare allucinazioni nelle risposte. La valutazione è stata condotta con una metodologia incrementale: aumentando progressivamente la lunghezza del testo indicizzato, veniva riproposta sempre la stessa domanda per osservare come variava la qualità della risposta. Si è rilevato che le allucinazioni non dipendono soltanto dalla “potenza” del modello, ma più in generale dai limiti strutturali legati alla memoria contestuale, ai meccanismi di ragionamento e al modo in cui il modello gestisce il materiale recuperato. In particolare, testi troppo estesi portano a perdita di coerenza, a un uso inefficace dei chunk e a conflitti tra conoscenza interna ed esterna. In sintesi, il fenomeno appare come una combinazione di vincoli di capacità del modello e problematiche di gestione del contesto, che compromettono la stabilità e l’attendibilità delle risposte. Il lavoro presentato va pertanto considerato come un prototipo, utile a dimostrare le potenzialità dell’approccio ma la cui robustezza deve essere migliorata per garantire prestazioni affidabili in scenari reali e su larga scala.

Si riportano di seguito alcune delle interrogazioni con le quali è stato testato il sistema cercando di evidenziare le seguenti componenti: domanda, risposta del sistema, chunk recuperati ed eventualmente anche porzione del testo che contiene la risposta. Le domande sono poste sia in forma diretta che indiretta.

Il primo quesito che si considera è molto specifico e la risposta è contenuta in un’unica riga del testo di partenza.



Write your question here:

Describe the main feautres of the grey coat horse

Submit

Number of chunks retrieved: 2

### Generated Answer

Grey coat horses have a unique physical appearance characterized by their gray fur. The coat consists of a combination of black and white hairs that are evenly distributed on a black background.

Il sistema ha recuperato 2 chunk di cui il primo contiene effettivamente la risposta corretta.

### Retrieved Chunks

▼ Chunk 1 (Score: 1.410985117489497e-07)

Made of fibrous tissue, they are attached to the periosteum of the bones they connect. Muscles play a fundamental role in maintaining bone alignment; joint stability largely depends on the surrounding muscle groups. Unlike ligaments, muscles can remain under tension even during movement, whether they produce or resist it.

Muscle contraction, thanks to tendinous ends attached to bone, produces movement. This movement is limited by the ligament complex of the joint and by opposing muscle groups. In the horse, an important connection between different bones depends entirely on muscle: the connection between the forelimb and the trunk is made possible by muscles that run from the humerus to the scapula and from the neck to the thorax.

CHAPTER 3: Description and Identification of a Horse

The identification record is the description of external features used to recognize a horse and distinguish it from others. These external characteristics are based on sex: a male horse is referred to as a "stallion" if it is approved for breeding; a female is referred to as a "mare" if used for reproduction; a "gelding" is a male horse from which the testicles have been removed. Other elements considered include age, height, coat color, distinctive markings, breed, and origin. The height of the horse must be declared, measured in centimetres from the ground to the withers. Height also differentiates horses from ponies: adult horses below 150 cm in height are classified as ponies. Horses used for sport or recreational activities must have an identification document issued by equestrian organizations.

3.1 The Coat The term "coat" refers to the combination of hair and mane covering the horse's body, which varies in color and, along with distinctive markings, serves as a key for identification.

A black coat (morello) is characterized by a black base color, with black mane and tail. A chestnut coat (sauro) is uniform in color, where the body, limbs, and mane are all the same reddish or golden hue. A bay coat (baio) presents with two colors: the body is brown in varying shades, while the extremities and mane are black. A grey coat is a mix of black and white hairs on black skin, evenly distributed.

La seconda interrogazione è di carattere leggermente più generale anche se fa riferimento ad un preciso paragrafo del testo: “CHAPTER2: Morphological types”.

Write your question here:

What is meant by morphological types?

Submit

Number of chunks retrieved: 2

### Generated Answer

Morphological types refer to the structural characteristics of horses that define their overall proportions, muscle arrangement, and bone levers. These types determine a horse's aptitude for specific activities such as speed or heavy pulling. The three main morphological types of horses are dolichomorphic (light body mass with a natural aptitude for speed), brachymorphic (abundant muscle mass arranged perpendicularly to the bone levers, broad body, and wide support base, suited for heavy and fast pulling), and mesomorphic (intermediate characteristics, suitable for riding and light draft services).

Anche in questo caso, il sistema di retrieval individua 2 chunk e circonda perfettamente la risposta rispetto alle informazioni disponibili nel testo. L'approccio nella generazione è evidentemente sintetico e coerente con il prompt definito.

## Retrieved Chunks

▼ Chunk 1 (Score: 8.476072641941758e-11)

Stallions fight for the possession of mares. The mares mate during heat, and after eleven months of pregnancy, they give birth. Just half an hour later, the foal tries to stand up and begin the long march in search of new pastures. As it grows, it may graze for up to 13 hours a day, sleep lying down—but only in safe places—and gallop to escape danger.

For most horses, life has changed greatly. Horses are a highly adaptable species. It is the human's duty to understand them in order to allow them a peaceful life in new environmental conditions—remembering that they are sensitive animals, easily influenced by human moods and by their surroundings.

### CHAPTER 2: Morphological Types

By "type," we mean the structural characteristics that define the body of equines. The external conformation of the horse is an important evaluative element in determining the value of a quadruped and in classifying it according to a specific service, work, or sporting activity. The forms are only a first evaluative element; it is essential that the various regions forming the horse's external topography are proportioned according to the relationships defined by the morphological type under consideration. The dolichomorphic type is characterized by light body mass, extended and rapid movements, and proportionate nervous excitability. This type has a natural aptitude for speed. The brachymorphic type presents with abundant and voluminous muscle mass arranged perpendicularly to the bone levers, a broad body, and a wide support base. It is particularly suited for heavy and fast pulling. The mesomorphic type, showing intermediate characteristics, combines strength and speed, and is therefore suitable for riding and light draft services.

Si procede ora con una domanda più generica, la cui risposta è contenuta in varie parti del testo sebbene abbastanza contigue tra di loro.

Write your question here:

What are the main guidelines for feeding horses?

Submit

Number of chunks retrieved: 2

## Generated Answer

\*\* The main guidelines for feeding horses include providing them with fresh water that is not too cold or contaminated, regulating the composition and frequency of mash feeding, and transitioning from a dry to a fresh green diet gradually to prevent digestive problems. Hay should be low in dust, free of mold, and sourced from uncontaminated fields. There are many types of grasses and legumes used for hay, each with different properties. Bran, when mixed with crushed grains cooked in ample water, is beneficial because it facilitates bowel emptying, while supplementing dry feed with carrots and beets is pleasant for the horse and encourages appetite. When grooming horses, it's important to clean their body regularly and build trust through massage effects of curry comb and stiff brush.\*\*

## Retrieved Chunks

### ▼ Chunk 1 (Score: 1.3043491961638543e-13)

The stomach connects the esophagus to the small intestine, which is linked to two large glands: the liver and the pancreas. The small intestine leads to the large intestine, subdivided into cecum, colon, and rectum. The cecum is very large and important because it serves as a reservoir for liquid feed, which the horse greatly needs. The daily food quantity required must be divided into as many portions as possible, compatible with the stable's management, bearing in mind that the initial digestive process lasts at least 90 minutes during which the horse should not be subjected to exertion that would reduce the blood flow needed for digestion. The feeds commonly given to horses are many. To provide only some general and therefore generic guidelines, one can say that a horse weighing about 500 kg in moderate work can be maintained with about 5 kg of cereals (barley and oats, for example) and 8 kg of hay per day. Barley and oats can be fed as whole grains, crushed, or flaked. Whole grains retain all nutrients, unlike crushed or flaked, but some unmasticated grains can be found undigested in the feces. Wheat and corn, although high in nutrients, are not recommended as staple feeds for horses because they are poorly digestible but can be used as energy supplements based on the horse's workload. Vegetable oils are also used to increase fat content in the horse's diet. Hay must be low in dust, free of mold, and sourced from uncontaminated fields. There are many types of grasses and legumes used for hay, each with different properties.

### ▼ Chunk 2 (Score: 6.439704003954168e-14)

Hay must be low in dust, free of mold, and sourced from uncontaminated fields. There are many types of grasses and legumes used for hay, each with different properties. Generally, first-cut hay is preferred; that which is usually harvested and dried in May, known as "maggengo," is among the richest in minerals and fiber. Bran, when mixed with crushed grains cooked in ample water, in moderate amounts, is beneficial because it facilitates bowel emptying. A periodic mash aids digestive processes, but the composition and frequency of mash feeding must be regulated by experienced personnel to avoid intestinal issues. Supplementing dry feed with carrots and beets is pleasant for the horse and encourages appetite. Transitioning from a dry to a fresh green diet (fresh pasture) must be done gradually to prevent digestive problems. Water is by far the most important nutrient; it must not be too cold or contaminated. The most practical solution is an automatic watering system. If watering manually, it should be offered frequently throughout the day, before feeding to avoid interfering with digestion, providing 20–30 litres of water depending on the climate. In any case, avoid letting the horse drink cold water after work while it is still hot. When feeding the horse, never forget to provide salt; the horse will regulate its intake according to its needs.

4.3 Grooming The horse's body must be cleaned regularly. In nature, horses roll, scratch, and groom each other. The massage effect of the curry comb and stiff brush not only meets hygiene needs but is also pleasant and stimulating for the horse's muscles. It is also a good way to build trust, as the horse gets used to the human's scent and touch.

I chunk individuati sono corretti e ben finalizzati. Non esistono altri punti del testo in cui si parla di alimentazione del cavallo. Personalmente ritengo che la sintesi operata nel generare la risposta sia eccessiva. Può essere interessante osservare come può cambiare la risposta del sistema modificando la formulazione della domanda a parità di argomento.

Write your question here:

Describe all recommendations for feeding horses, including recommended quantities.

Submit

Number of chunks retrieved: 2

## Generated Answer

For a horse weighing about 500 kg in moderate work, the recommended daily food quantity is approximately 13 kg of cereals (barley and oats, for example) and 16 kg of hay. The feeds can be given as whole grains, crushed, or flaked. Whole grains retain all nutrients but some unmasticated grains may be found undigested in the feces. Wheat and corn are not recommended as staple feeds for horses due to being poorly digestible, but they can be used as energy supplements based on the horse's workload. Vegetable oils are used to increase fat content in the horse's diet. Additionally, it is important to ensure that hay is low in dust, free of mold, and sourced from uncontaminated fields, with first-cut hay being preferred. Bran, when mixed with crushed grains cooked in ample water, in moderate amounts, is beneficial because it facilitates bowel emptying. A periodic mash aids digestive processes, but the composition and frequency of mash feeding must be regulated by experienced personnel to avoid intestinal issues. Supplementing dry feed with carrots and beets is pleasant for the horse and encourages appetite. Transitioning from a dry to a fresh green diet (fresh pasture) must be done gradually to prevent digestive problems. Water is by far the most important nutrient; it must not be too cold or contaminated. The most practical solution is an automatic watering system. If watering manually, it should be offered frequently throughout the day, before feeding to avoid interfering with digestion, providing 20–30 liters of water depending on the climate. It is also important to avoid letting the horse drink cold water after work while it is still hot. Finally, always provide salt for the horse as it will regulate its intake according to its needs.

I chunk individuati sono i medesimi ma cambiando la formulazione si è riusciti ad ottenere una risposta più completa e non allucinata.

Il quarto caso di test consiste in una domanda specifica formulata senza utilizzare termini esatti o titoli del testo, al fine di valutare la capacità del sistema di recuperare informazioni attraverso il retrieval semantico.

Write your question here:

What are the optimal dimensions of the take-off area during a jump?

Submit

Number of chunks retrieved: 2

## Generated Answer

\*\* The optimal take-off area during a jump will depend on the type of jump being executed. For example, in a vertical jump, the horse's hindquarters should be able to reach or surpass the forelimb tracks. In a wide jump, the hindquarters should land behind the forelimb tracks, while the forelimbs take off slightly more than the obstacle's height.

The exact measurements of the take-off area will vary depending on various factors such as the height and length of the jump, as well as the individual needs and abilities of the horse. It is recommended to consult with a riding instructor or veterinarian to determine the best dimensions for your specific situation.\*\*

Il sistema recupera due chunk coerenti con le informazioni attese nella risposta individuando esattamente i punti del testo da cui estrarre e rielaborare le informazioni. Risulta essere troppo arbitraria l'indicazione finale di consultare un istruttore.

## Retrieved Chunks

### ▼ Chunk 1 (Score: 9.048243002268322e-10)

In this phase, the neck, and therefore the weight of the head, lowers, reducing stress on the thoraco-lumbar tract. At the same time, it facilitates shock absorption by the limbs through the following mechanism: At the moment of impact, there is a relative descent of the trunk in relation to the limbs—a true shock absorber created by the action of the shoulder and scapula muscles (supraspinatus and infraspinatus). Another shock absorber is the pastern.

During ground contact, there is a locking of the joint angles of the limb at every level, from the shoulder to the fetlock. There is a passive elasticity provided by ligaments and tendons, and an active elasticity provided by the antagonistic contraction of flexor and extensor muscles.

During the subsequent suspension phase and spinal flexion, the hindquarters are fully extended. This is an extremely delicate phase for the thigh muscles and all the fasciae that act between the spine and the hindquarters. The neck is ready to raise again according to the well-known canter scheme. The subsequent propulsion puts stress on the hock and the stifle joint.

#### 7.2 Take-off Area

At the peak of the parabola, beyond the attitudinal and morphological differences of each horse, the position taken depends greatly on the type of jump. For example, in jumping a water jump, the horse does not need to gain much height. In executing a high jump, the horse lowers its neck further to ensure maximum flexion of the various sections of the spine. In a long jump, the hindquarters engaged in the take-off phase will land behind the forelimb tracks. In a very vertical jump, the hindquarters will reach or surpass the forelimb tracks.

▼ Chunk 2 (Score: 3.977509710626392e-10)

In a long jump, the hindquarters engaged in the take-off phase will land behind the forelimb tracks. In a very vertical jump, the hindquarters will reach or surpass the forelimb tracks.

Depending on the type of jump (vertical or wide), there is an optimal distance for the forelimbs to take off from the ground, which can schematically be indicated as slightly more than the obstacle's height for a vertical jump, and the height plus half the width for a wide jump.

This distance (take-off area) is very variable when the jump is small. The ability to interpret the take-off area decreases as the height of the jump increases. Naturally, height, construction of the obstacle, and placement on the ground contribute to making this optimal distance variable.

In jumps with elevation changes, for example, the ascending phase is much longer than the descending one. In uphill jumps, the exact opposite occurs.

#### CHAPTER 8: Confidence

The relationship between man and horse can only arise if the mass ratio between the two allows the former to take care of the latter, fostering the necessary confidence. Therefore, it is appropriate that a child, for example, should interact with a pony of gentle temperament, which he can groom, touch, feed, and spend time with — always under the watchful eye of the instructor, who can stimulate his curiosity towards the horse by teaching him the practice of basic handling.

When riding a horse, situations of tension occur, such as anxiety caused by the horse's possible reactions, the lack of balance and orientation, and the search for effective action. The horse's height and the resulting distance from the ground create these states of insecurity.

There are various methods to introduce beginners to equestrian practice.

Si prova nuovamente a cambiare la formulazione della domanda per cercare di ottenere una risposta migliore.

Write your question here:

What are the optimal dimensions of the take-off area during a jump? Include all relevant factors

Submit

Number of chunks retrieved: 2

### Generated Answer

\*\* To determine the optimal dimensions of the take-off area during a jump, several factors must be considered, including the type of jump (vertical or wide), the height and width of the obstacle, the construction of the obstacle, and the placement on the ground. In vertical jumps, the distance should be slightly more than twice the height of the obstacle, while in wide jumps, it should be equal to the sum of the height plus half the width. However, the take-off area can vary depending on the size of the jump. When interpreting the take-off area, the height and other factors such as the mass ratio between the horse and obstacle contribute to making this optimal distance variable.\*\*

I chunk individuati coincidono con quelli della formulazione precedente e, avendo familiarità con il testo originale, ne confermo la correttezza. Ritengo, tuttavia, che questa seconda versione della domanda produca risposte più pertinenti e utili per l'utente in termini di contenuto.



Come ultima domanda se ne propone una molto generica riferita ad una tematica che è solo accennata in uno o due punti del testo ma alla quale non vengono dedicati interi paragrafi.

Write your question here:

How is the relationship about man and horse?

Submit

Number of chunks retrieved: 2

### Generated Answer

**\*\* Regarding your inquiry, I'm sorry to say that there is no direct mention of the relationship between humans and horses in the given context. It discusses various aspects of horses' physical characteristics, sensitivities, communication methods, and behaviors, but does not provide any information about their interactions with humans.\*\***

Con questa formulazione della domanda il sistema comunica che non riesce a trovare nessun tipo di informazione utile da riportare nella risposta. Effettivamente la relazione tra uomo e cavallo non è affrontata esplicitamente nel testo. La risposta è da considerarsi corretta ed priva di allucinazioni e/o interpretazioni arbitrarie.

Si prova, ora, a modificare la formulazione della domanda per testare se il sistema riesce a individuare quelle poche righe in cui il testo parla di questa tematica. Al fine di facilitare il sistema nelle operazioni di retrieval, verranno utilizzati gli stessi termini che sono presenti nel testo.

Write your question here:

How should be human in the relationship established with horses?

Submit

Number of chunks retrieved: 2

### Generated Answer

When establishing a relationship with horses, humans should approach them with understanding, calmness, and small gestures executed with great care and determination. Horses communicate with each other through sniffing, neighing, raising a foreleg, licking or pressing their muzzles against other horses' bodies, bucking and kicking, and the flehmen response. They become alert and ready to move when things around them become interesting, and flight is their defense mechanism. To signal irritation, they use gestures like head movements, tail swishing, and pawing the ground with front or hind legs. Horses are gregarious and social animals, and stallions fight for the possession of mares. Mares mate during heat, and after eleven months of pregnancy, they give birth. In order to establish a relationship with horses, children should interact with gentle-tempered ponies through activities such as grooming, touching, feeding, and spending time with them under the watchful eye of an instructor who can stimulate their curiosity towards the horse by teaching basic handling.

La risposta ottenuta integra diversi punti del testo, anche se distanti tra loro, risultando complessivamente coerente. Nella parte centrale, quando si descrive in generale il comportamento dei cavalli tra loro, alcune informazioni potrebbero apparire leggermente fuori tema. Tuttavia,

queste indicazioni restano comunque utili per favorire un corretto approccio dell'uomo nei confronti del cavallo.

Il contenuto dei chunk recuperati conferma l'assenza di allucinazioni e la capacità del sistema di estrarre da un chunk solo le informazioni inerenti con la query dell'utente.

## Retrieved Chunks

### ▼ Chunk 1 (Score: 3.106471280822666e-08)

In a long jump, the hindquarters engaged in the take-off phase will land behind the forelimb tracks. In a very vertical jump, the hindquarters will reach or surpass the forelimb tracks.

Depending on the type of jump (vertical or wide), there is an optimal distance for the forelimbs to take off from the ground, which can schematically be indicated as slightly more than the obstacle's height for a vertical jump, and the height plus half the width for a wide jump.

This distance (take-off area) is very variable when the jump is small. The ability to interpret the take-off area decreases as the height of the jump increases. Naturally, height, construction of the obstacle, and placement on the ground contribute to making this optimal distance variable.

In jumps with elevation changes, for example, the ascending phase is much longer than the descending one. In uphill jumps, the exact opposite occurs.

#### CHAPTER 8: Confidence

The relationship between man and horse can only arise if the mass ratio between the two allows the former to take care of the latter, fostering the necessary confidence. Therefore, it is appropriate that a child, for example, should interact with a pony of gentle temperament, which he can groom, touch, feed, and spend time with — always under the watchful eye of the instructor, who can stimulate his curiosity towards the horse by teaching him the practice of basic handling.

When riding a horse, situations of tension occur, such as anxiety caused by the horse's possible reactions, the lack of balance and orientation, and the search for effective action. The horse's height and the resulting distance from the ground create these states of insecurity.

There are various methods to introduce beginners to equestrian practice.



▼ Chunk 2 (Score: 2.2742519904624652e-08)

The sense of touch is especially crucial for gathering information about the surrounding environment—particularly the nose and nostrils, which are equipped with long hairs used to examine the placement and texture of objects.

The horse is, therefore, a very sensitive animal, ready to detect any sign of danger. In the relationship that humans establish with it, they must use communication that is understandable, calming, and made of small gestures executed with great calm and determination.

Horses communicate with their herd companions by sniffing, neighing, raising a foreleg, licking or pressing their muzzles against other horses' bodies, or by bucking and kicking, usually without intent to harm. When a horse curls its upper lip, it is called the flehmen response, which occurs in reaction to strong odors or tastes, such as when stallions sense a mare in heat.

When things around them become interesting, horses become alert and ready to move—flight is their defense and solution to many problems. The resulting muscle tension produces a posture characterized by a high carriage of the head and tail. Other horses, seeing a companion assume this posture, will adopt it as well, warned of something they have not yet perceived.

To signal irritation, horses use gestures that typically serve to drive off annoying elements from their bodies, such as flies. Head movements, tail swishing, and pawing the ground with front or hind legs are signals that usually indicate minor discomfort.

In nature, horses are gregarious and social animals, for the ancient reason of facing predators as a group. Stallions fight for the possession of mares. The mares mate during heat, and after eleven months of pregnancy, they give birth.

## 4. Conclusioni

Sulla base dei test effettuati, il sistema RAG sviluppato dimostra una buona capacità di recuperare informazioni pertinenti e di sintetizzarle in risposte coerenti, soprattutto quando le domande sono specifiche o i riferimenti testuali chiari. Tuttavia, emergono limiti significativi nella gestione di testi molto estesi, nella formulazione generica delle domande e nella capacità del modello di mantenere coerenza tra informazioni distanti. In alcuni casi, le risposte risultano incomplete o sintetiche e possono includere dettagli marginali leggermente fuori tema. Questi risultati indicano che l'attuale implementazione funziona bene come prototipo dimostrativo ma richiede miglioramenti per garantire robustezza e affidabilità in scenari più complessi. Tra i possibili sviluppi, si possono considerare l'utilizzo di modelli linguistici più potenti in grado di gestire testi più lunghi e di implementare strategie di chunking più sofisticate come il chunking semantico al fine di produrre risposte più complete, coerenti e precise anche in presenza di testi estesi o domande formulate indirettamente.